

ĐẠI HỌC BÁCH KHOA HÀ NỘI

KHOA TOÁN - TIN

BÀI TIỂU LUẬN CUỐI KỲ

MÔN: SUY LUẬN THỐNG KÊ

ĐỀ TÀI:

MÔ HÌNH HỒI QUY TUYẾN TÍNH BỘI TRONG DỰ
DOÁN GIÁ CƯỚC DỊCH VỤ TAXI: NGHIÊN CỨU
THỰC NGHIỆM TỪ DỮ LIỆU YELLOW TAXI TẠI
THÀNH PHỐ NEW YORK

Giảng viên hướng dẫn: PGS.TS. Nguyễn Thị Thu Thủy

Sinh viên thực hiện: Đào Tất Thành

MSSV: 20237485

Mã học phần: MI3031

Mã lớp học: 163641

Học kỳ: 2025.1

Hà Nội, 12/2025

MỤC LỤC

1	Giới thiệu	2
1.1	Lý do chọn đề tài	2
1.2	Mục tiêu nghiên cứu	2
1.3	Câu hỏi nghiên cứu	2
1.4	Đối tượng và phạm vi nghiên cứu	3
1.5	Cấu trúc bài báo cáo	3
2	Cơ sở lý thuyết	3
2.1	Hệ số tương quan	3
2.2	Mô hình hồi quy tuyến tính bội	4
2.3	Ước lượng tham số	6
2.4	Suy luận thống kê	6
2.5	Dự đoán	8
3	Dữ liệu và phương pháp	8
3.1	Nguồn dữ liệu	8
3.2	Mô tả biến số trong mô hình	10
3.3	Quy trình thu thập và xử lý dữ liệu	11
3.4	Kỹ thuật thống kê sử dụng	12
3.5	Công cụ phân tích	13
4	Kết quả và phân tích	13
4.1	Thống kê mô tả mẫu nghiên cứu	14
4.2	Phân tích tương quan	14
4.3	Kết quả mô hình hồi quy	15
4.4	Kiểm định các giả thiết của mô hình hồi quy	18
4.5	Kết quả mô hình cuối cùng	19
5	Nhận xét và kết luận	21
5.1	Ý nghĩa thống kê của kết quả	21
5.2	Ý nghĩa thực tiễn của kết quả	21
5.3	Phản biện kết quả và hạn chế của nghiên cứu	22
5.4	Đề xuất mở rộng nghiên cứu	22
5.5	Kết luận	23

Tài liệu tham khảo

Phụ lục

1 Giới thiệu

1.1 Lý do chọn đề tài

Dịch vụ taxi là một phần không thể thiếu trong hệ thống giao thông đô thị, đặc biệt tại các thành phố lớn như New York. Với hàng triệu chuyến xe được thực hiện mỗi tháng, việc hiểu rõ các yếu tố ảnh hưởng đến giá cước taxi không chỉ có ý nghĩa quan trọng đối với hành khách mà còn đối với các công ty vận tải và nhà hoạch định chính sách giao thông.

Giá cước taxi được xác định bởi nhiều yếu tố khác nhau, từ các yếu tố trực tiếp như quãng đường di chuyển và thời gian hành trình, đến các yếu tố gián tiếp như thời điểm trong ngày và ngày trong tuần. Tuy nhiên, mức độ ảnh hưởng của từng yếu tố này đến giá cước cuối cùng chưa được lượng hóa một cách rõ ràng.

Mô hình hồi quy tuyến tính bội là công cụ thống kê phù hợp để phân tích mối quan hệ giữa một biến phụ thuộc và nhiều biến độc lập. Việc áp dụng phương pháp này vào phân tích giá cước taxi sẽ giúp xác định và đo lường ảnh hưởng của từng yếu tố một cách khoa học và có cơ sở thống kê.

1.2 Mục tiêu nghiên cứu

1.2.1 Mục tiêu tổng quát

Xây dựng mô hình hồi quy tuyến tính bội để phân tích các yếu tố ảnh hưởng đến giá cước của dịch vụ Yellow taxi tại thành phố New York.

1.2.2 Mục tiêu cụ thể

- Xác định mối quan hệ giữa giá cước và các yếu tố: quãng đường di chuyển, thời gian hành trình, giờ cao điểm, và ngày cuối tuần.
- Đánh giá mức độ ảnh hưởng của từng yếu tố đến giá cước thông qua các hệ số hồi quy.
- Kiểm định ý nghĩa thống kê của các biến độc lập trong mô hình.
- Xây dựng mô hình dự báo giá cước Yellow taxi dựa trên các biến có ý nghĩa thống kê.

1.3 Câu hỏi nghiên cứu

Nghiên cứu này tập trung trả lời các câu hỏi sau:

- Quãng đường di chuyển và thời gian hành trình có ảnh hưởng như thế nào đến giá cước taxi?
- Giá cước taxi vào giờ cao điểm (7-9 giờ sáng và 16-19 giờ chiều) có khác biệt so với các khung giờ khác không?
- Có sự khác biệt về giá cước giữa các chuyến đi vào ngày cuối tuần và ngày thường không?
- Trong các yếu tố được xem xét, yếu tố nào có ảnh hưởng lớn nhất đến giá cước?
- Mô hình hồi quy tuyến tính bội có khả năng giải thích được bao nhiêu phần trăm sự biến thiên của giá cước?

1.4 Đối tượng và phạm vi nghiên cứu

1.4.1 Đối tượng nghiên cứu

- Giá cước của các chuyến xe Yellow Taxi tại New York.
- Các yếu tố ảnh hưởng được quan tâm bao gồm: quãng đường di chuyển, thời gian hành trình, biến giả giờ cao điểm, và biến giả ngày cuối tuần.

1.4.2 Phạm vi nghiên cứu

- Phạm vi không gian: Thành phố New York, Hoa Kỳ.
- Phạm vi thời gian: Dữ liệu các chuyến xe Yellow Taxi trong tháng 11 năm 2025.

1.4.3 Giới hạn nghiên cứu

- Nghiên cứu chỉ tập trung vào dịch vụ Yellow taxi, không bao gồm các dịch vụ khác như Green taxi hoặc For-hive taxi.
- Các yếu tố như điều kiện thời tiết, tình trạng giao thông, hoặc vị trí địa lý cụ thể không được đưa vào mô hình.

1.5 Cấu trúc bài báo cáo

Bài báo cáo được tổ chức thành các phần như sau:

- **Phần 1: Giới thiệu** – Trình bày lý do chọn đề tài, mục tiêu nghiên cứu, câu hỏi nghiên cứu, đối tượng và phạm vi nghiên cứu.
- **Phần 2: Cơ sở lý thuyết** – Giới thiệu lý thuyết về hồi quy tuyến tính bội, các giả định của mô hình, phương pháp kiểm định và đánh giá mô hình.
- **Phần 3: Dữ liệu và phương pháp** – Mô tả nguồn dữ liệu, quy trình thu thập và xử lý dữ liệu, phương pháp phân tích thống kê được sử dụng.
- **Phần 4: Kết quả và phân tích** – Trình bày thống kê mô tả, phân tích tương quan, kết quả ước lượng mô hình hồi quy, kiểm định các giả thuyết thống kê.
- **Phần 5: Nhận xét và kết luận** – Phân tích ý nghĩa của các kết quả, so sánh với các nghiên cứu trước, giải thích các phát hiện chính. Tóm tắt các kết quả chính, đề xuất ứng dụng thực tiễn, hạn chế của nghiên cứu và hướng phát triển trong tương lai.

2 Cơ sở lý thuyết

2.1 Hệ số tương quan

2.1.1 Hệ số tương quan tổng thể

Hệ số tương quan tổng thể ρ đo mức độ quan hệ tuyến tính giữa hai biến ngẫu nhiên X và Y :

$$\rho = \rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} = \frac{E[(X - \mu_X)(Y - \mu_Y)]}{\sigma_X \sigma_Y} \quad (2.1)$$

Tính chất:

- $-1 \leq \rho \leq 1$
- $\rho = 1$: Quan hệ tuyến tính dương hoàn hảo
- $\rho = -1$: Quan hệ tuyến tính âm hoàn hảo
- $\rho = 0$: Không có quan hệ tuyến tính (nhưng có thể có quan hệ phi tuyến)

2.1.2 Hệ số tương quan mẫu

Từ mẫu $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$, hệ số tương quan mẫu được tính bởi:

$$r = \frac{S_{xy}}{\sqrt{S_{xx} \cdot S_{yy}}} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (2.2)$$

trong đó:

- $S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$
- $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$
- $S_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2$

2.1.3 Tương quan và nhân quả

Tương quan không có nghĩa là xảy ra X nhất định xảy ra Y. Khi hai biến X và Y có tương quan cao, có thể do:

1. X ảnh hưởng đến Y .
2. Y ảnh hưởng đến X .
3. Cả X và Y đều bị ảnh hưởng bởi một biến thứ ba.
4. Tương quan ngẫu nhiên.

2.1.4 Vấn đề đa cộng tuyến

Đa cộng tuyến là hiện tượng các biến độc lập trong mô hình có mối tương quan tuyến tính mạnh với nhau. Khi xảy ra đa cộng tuyến:

- Phương sai của các ước lượng hệ số hồi quy ($Var(\hat{\beta}_j)$) sẽ bị cao bất thường.
- Làm giảm giá trị thống kê t , dẫn đến việc khó bác bỏ giả thuyết H_0 .
- Dấu của các hệ số hồi quy có thể bị đảo ngược so với lý thuyết.

2.2 Mô hình hồi quy tuyến tính bội

2.2.1 Dạng tổng quát

Mô hình hồi quy tuyến tính bội mô tả mối quan hệ giữa một biến phụ thuộc Y với k biến độc lập $x_1, x_2, \dots, x_k$:

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + \varepsilon_i, \quad i = 1, 2, \dots, n$$

trong đó:

- Y_i : Giá trị quan sát thứ i của biến phụ thuộc
- x_{ij} : Giá trị của biến độc lập thứ j tại quan sát i
- $\beta_0, \beta_1, \dots, \beta_k$: Các hệ số hồi quy cần ước lượng
- ε_i : Sai số ngẫu nhiên

2.2.2 Biểu diễn dạng ma trận

Mô hình được viết gọn dưới dạng ma trận:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \quad (2.3)$$

trong đó:

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}_{n \times 1}, \quad \mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1k} \\ 1 & x_{21} & x_{22} & \cdots & x_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{nk} \end{pmatrix}_{n \times p}$$

$$\boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix}_{p \times 1}, \quad \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}_{n \times 1}$$

với $p = k + 1$ là số tham số cần ước lượng.

2.2.3 Hệ thống giả thiết

Giả thiết 1 Giả sử rằng sai số ngẫu nhiên $\boldsymbol{\varepsilon}$ thỏa mãn các điều kiện sau:

1. Độc lập theo nghĩa xác suất.
2. $E(\varepsilon_i) = 0$ và $\text{Var}(\varepsilon_i) = \sigma^2$ với mọi i .
3. Có phân phối chuẩn.

Giả thiết 2

1. Việc ước lượng dựa trên cơ sở mẫu ngẫu nhiên $(\mathbf{X}, \mathbf{y})$.
2. $E(\boldsymbol{\varepsilon}|\mathbf{X}) = \mathbf{0}$ (ma trận 0).
3. $E(\boldsymbol{\varepsilon}^T \boldsymbol{\varepsilon}|\mathbf{X}) = \sigma^2 I_n$, I_n là ma trận đơn vị cấp n .
4. Tồn tại ma trận nghịch đảo $(\mathbf{X}^T \mathbf{X})^{-1}$.

Giải thích:

- Giả thiết 1 tập trung vào tính chất của sai số ngẫu nhiên: độc lập, kỳ vọng bằng 0, phương sai đồng nhất, và phân phối chuẩn. Đây là điều kiện đủ cho suy diễn thống kê chính xác (kiểm định t, F, khoảng tin cậy).
- Giả thiết 2 tập trung vào điều kiện kỹ thuật của ma trận thiết kế và mẫu dữ liệu, đảm bảo ước lượng Bình phương nhỏ nhất tồn tại và có tính chất tốt (không chệch, phương sai nhỏ nhất).

2.3 Ước lượng tham số

2.3.1 Phương pháp Bình phương nhỏ nhất (BPNN)

Phương pháp BPNN tìm $\hat{\beta}$ sao cho tổng bình phương phần dư nhỏ nhất:

$$L(\beta) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta) \longrightarrow \min$$

Định lý: Dưới giả thiết 2, ước lượng BPNN là:

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} \quad (2.4)$$

(Chứng minh xem Phụ lục A.1)

2.3.2 Tính chất của ước lượng Bình phương nhỏ nhất

Dưới giả thiết 2:

Ước lượng BPNN là không chệch:

$$E(\hat{\beta}|\mathbf{X}) = \beta$$

(Chứng minh xem Phụ lục A.2)

Ma trận hiệp phương sai của ước lượng:

$$\text{Var}(\hat{\beta}|\mathbf{X}) = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1} \quad (2.5)$$

Hệ quả: $\text{Var}(\hat{\beta}_j) = \sigma^2 C_{jj}$, với C_{jj} là phần tử đường chéo thứ j của ma trận $\mathbf{C} = (\mathbf{X}^T \mathbf{X})^{-1}$.

(Chứng minh xem Phụ lục A.3)

Định lý Gauss-Markov: Nếu Giả thiết 2 được thỏa mãn thì các ước lượng thu được từ phương pháp bình phương cực tiểu là các ước lượng tuyến tính, không chệch và có phương sai nhỏ nhất trong lớp các ước lượng tuyến tính không chệch.

2.3.3 Ước lượng phương sai của sai số

Phương sai σ^2 được ước lượng không chệch bởi:

$$s^2 = \frac{SSE}{n - p} = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - k - 1} \quad (2.6)$$

(Chứng minh xem Phụ lục A.4)

trong đó SSE là tổng bình phương sai số và $n - p = n - k - 1$ là bậc tự do. Sai số chuẩn của hệ số hồi quy:

$$se(\hat{\beta}_j) = s\sqrt{C_{jj}} \quad (2.7)$$

2.4 Suy luận thống kê

Lưu ý: Các kết quả trong phần này yêu cầu thỏa mãn cả 2 giả thiết.

2.4.1 Phân phối của ước lượng

Dưới giả thiết mạnh:

$$\hat{\beta} \sim N(\beta, \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1})$$

Đặc biệt:

$$\hat{\beta}_j \sim N(\beta_j, \sigma^2 C_{jj})$$

2.4.2 Kiểm định ý nghĩa của mô hình

Cặp giả thuyết kiểm định:

- $H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$ (Mô hình không có ý nghĩa)
- $H_1 : \exists j \in \{1, \dots, k\} : \beta_j \neq 0$ (Mô hình có ý nghĩa)

Tiêu chuẩn kiểm định:

$$F_0 = \frac{SS_R/k}{SS_E/(n-p)} = \frac{MS_R}{MS_E} \quad (2.8)$$

Nếu giả thuyết $H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$ là đúng thì F_0 có phân phối F với $\nu_1 = k$ và $\nu_2 = n - p$ bậc tự do.

Giá trị quan sát của tiêu chuẩn kiểm định:

Dựa trên dữ liệu quan sát được $\{(x_{i1}, x_{i2}, \dots, x_{ik}, y_i), i = 1, \dots, n\}$, tính giá trị quan sát của tiêu chuẩn kiểm định:

$$f_0 = \frac{SS_R/k}{SS_E/(n-p)} = \frac{MS_R}{MS_E} \quad (2.9)$$

Miền bác bỏ giả thuyết H_0 :

$$W_\alpha = \{f_0 \mid f_0 > f_\alpha(k, n-p)\} \quad (2.10)$$

Ở đây, $f_\alpha(k, n-p)$ được xác định từ bảng giá trị tới hạn phân phối F với $\nu_1 = k$ và $\nu_2 = n - p$ bậc tự do.

Kết luận:

Xét xem f_0 có thuộc W_α hay không để kết luận:

- (a) Nếu $f_0 \in W_\alpha$ thì bác bỏ giả thuyết H_0 .
- (b) Nếu $f_0 \notin W_\alpha$ thì chưa có cơ sở để bác bỏ giả thuyết H_0 .

2.4.3 Kiểm định hệ số hồi quy riêng

Cặp giả thuyết kiểm định:

- $H_0 : \beta_j = \beta_{j0}$ (thường $\beta_{j0} = 0$, tức biến x_j không có tác động)
- $H_1 : \beta_j \neq \beta_{j0}$ (Biến x_j có tác động)

Tiêu chuẩn kiểm định:

$$T_0 = \frac{\hat{\beta}_j - \beta_{j0}}{\sqrt{\sigma^2 C_{jj}}} \quad (2.11)$$

Nếu giả thuyết $H_0 : \beta_j = \beta_{j0}$ là đúng thì $T_0 \sim t(n-p)$.

Dựa trên dữ liệu quan sát được $\{(x_{i1}, x_{i2}, \dots, x_{ik}, y_i), i = 1, \dots, n\}$, tính giá trị quan sát của tiêu chuẩn kiểm định:

$$t_0 = \frac{\hat{\beta}_j - \beta_{j0}}{se(\hat{\beta}_j)} \quad (2.12)$$

Miền bác bỏ giả thuyết H_0 :

$$W_\alpha = \{t_0 \mid |t_0| > t_{\alpha/2}(n-p)\} \quad (2.13)$$

Ở đây, $t_{\alpha/2}(n-p)$ được xác định từ bảng giá trị tới hạn phân phối t với $n-p$ bậc tự do.

Kết luận:

Xét xem t_0 có thuộc W_α hay không để kết luận.

- (a) Nếu $t_0 \in W_\alpha$ thì bác bỏ giả thuyết H_0 .
- (b) Nếu $t_0 \notin W_\alpha$ thì chưa có cơ sở để bác bỏ giả thuyết H_0 .

2.5 Dự đoán

2.5.1 Dự đoán điểm

Với quan sát mới có giá trị biến độc lập $\mathbf{x}_0$, giá trị dự đoán:

$$\hat{y}_0 = \mathbf{x}_0^T \hat{\boldsymbol{\beta}} = \hat{\beta}_0 + \hat{\beta}_1 x_{01} + \cdots + \hat{\beta}_k x_{0k}$$

2.5.2 Khoảng dự đoán cho quan sát mới

Khoảng dự đoán $(1 - \alpha)100\%$ cho Y_0 :

$$\hat{y}_0 \pm t_{\alpha/2, n-k-1} \cdot s \sqrt{1 + \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0} \quad (2.14)$$

(Chứng minh xem Phụ lục A.5)

3 Dữ liệu và phương pháp

3.1 Nguồn dữ liệu

3.1.1 Giới thiệu nguồn dữ liệu

Nghiên cứu sử dụng bộ dữ liệu **Yellow Taxi Trip Records** được công bố bởi NYC Taxi and Limousine Commission (TLC) – cơ quan quản lý và cấp phép cho các dịch vụ vận tải hành khách tại thành phố New York, Hoa Kỳ.

Đây là nguồn dữ liệu chính thức, được thu thập tự động từ hệ thống đồng hồ tính tiền và thiết bị GPS gắn trên các Yellow taxi hoạt động tại New York. Dữ liệu được tải về từ trang web chính thức của TLC tại địa chỉ: <https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page>.

Bộ dữ liệu được cung cấp miễn phí dưới dạng file Parquet, cập nhật hàng tháng và chứa thông tin chi tiết về từng chuyến đi của Yellow taxi.

3.1.2 Phạm vi dữ liệu

- **Thời gian:** Tháng 11 năm 2025
- **Loại phương tiện:** Yellow Taxi là loại taxi truyền thống
- **Khu vực:** Thành phố New York và các vùng lân cận
- **Kích thước mẫu:** Sau khi làm sạch và xử lý, nghiên cứu sử dụng mẫu ngẫu nhiên gồm 5000 quan sát để đảm bảo tính đại diện và khả năng tính toán.

3.1.3 Cấu trúc bộ dữ liệu gốc

Bộ dữ liệu Yellow Taxi Trip Records gốc chứa 19 trường thông tin cho mỗi chuyến đi. Bảng 3.1 trình bày chi tiết các trường dữ liệu có trong bộ dữ liệu gốc:

Bảng 1: Cấu trúc các trường dữ liệu trong bộ dữ liệu Yellow Taxi

STT	Tên trường	Kiểu dữ liệu	Mô tả
1	VendorID	Integer	Mã nhà cung cấp dịch vụ (1 = Creative Mobile, 2 = VeriFone)
2	tpep_pickup_datetime	Datetime	Thời điểm đồng hồ tính tiền bắt đầu (đón khách)
3	tpep_dropoff_datetime	Datetime	Thời điểm đồng hồ tính tiền kết thúc (trả khách)
4	passenger_count	Integer	Số lượng hành khách (do tài xế nhập)
5	trip_distance	Float	Quãng đường di chuyển tính bằng dặm (miles)
6	RatecodeID	Integer	Mã loại giá (1=Standard, 2=JFK, 3=Newark, 4=Nassau/Westchester, 5=Negotiated, 6=Group)
7	store_and_fwd_flag	String	Cờ lưu trữ và chuyển tiếp (Y/N)
8	PULocationID	Integer	Mã vùng đón khách (TLC Taxi Zone)
9	DOLocationID	Integer	Mã vùng trả khách (TLC Taxi Zone)
10	payment_type	Integer	Phương thức thanh toán (1=Credit card, 2=Cash, 3=No charge, 4=Dispute, 5=Unknown, 6=Voided)
11	fare_amount	Float	Giá cước tính theo đồng hồ (USD)
12	extra	Float	Phụ phí (giờ cao điểm \$0,50, đêm \$1.00)
13	mta_tax	Float	Thuế MTA tự động (\$0,50)
14	tip_amount	Float	Tiền tip (chỉ ghi nhận khi thanh toán thẻ)
15	tolls_amount	Float	Tổng phí cầu đường
16	improvement_surcharge	Float	Phụ phí cải thiện (\$0,30)
17	total_amount	Float	Tổng tiền thanh toán (USD)
18	congestion_surcharge	Float	Phụ phí tắc nghẽn (áp dụng tại Manhattan)
19	Airport_fee	Float	Phí sân bay (\$1,25 cho đón/trả tại LaGuardia, JFK)

Nguồn: NYC Taxi and Limousine Commission

3.1.4 Cơ chế tính giá cước taxi tại New York

Để hiểu rõ tại sao giá cước taxi không thể được xác định chỉ dựa trên một yếu tố duy nhất như quãng đường di chuyển, cần nắm được cơ chế tính giá cước của Yellow Taxi tại New York theo quy định của NYC Taxi and Limousine Commission.

Bảng 2: Biểu giá Yellow Taxi tại New York (áp dụng từ 2024)

Thành phần	Mức phí	Ghi chú
Giá mở cửa (Initial charge)	\$3,00	Áp dụng ngay khi lên xe
Phí theo quãng đường	\$0,70 / 0,2 dặm	Tương đương \$3.50/dặm
Phí theo thời gian chờ	\$0,70 / 60 giây	Khi xe dừng hoặc < 12 mph
Phụ phí giờ cao điểm	+\$1,00	16:00 - 20:00 các ngày trong tuần
Phụ phí đêm khuya	+\$1,00	20:00 - 06:00
Thuế MTA State	+\$0,50	Bắt buộc mọi chuyến
Phụ phí cải thiện	+\$1,00	Bắt buộc mọi chuyến
Phụ phí tắc nghẽn	+\$2,50	Đón/trả khách dưới 96th St, Manhattan

Nguồn: NYC Taxi and Limousine Commission (2024)

Cơ chế tính kép: Điểm đặc biệt quan trọng trong hệ thống tính giá taxi New York là cơ chế tính kép. Đồng hồ tính tiền hoạt động theo nguyên tắc: khi xe di chuyển với tốc độ trên 12 mph (khoảng 19 km/h), giá cước được tính theo quãng đường; khi xe dừng lại hoặc di chuyển chậm hơn 12 mph giá cước chuyển sang tính theo thời gian. Hai chế độ này hoạt động xen kẽ trong suốt hành trình.

Hệ quả đối với phân tích: Với thực tế khó đo lường được chính xác tốc độ nhanh chậm của xe chứng minh được rằng việc không thể có một công thức toán học chính xác nào giải thích đầy đủ sự biến thiên của giá cước. Do đó, nghiên cứu này áp dụng mô hình hồi quy tuyến tính bội với các biến:

- Quãng đường: Phản ánh thành phần tính theo khoảng cách.
- Thời gian hành trình: Phản ánh thành phần tính theo thời gian, đặc biệt quan trọng khi kẹt xe.
- Giờ cao điểm: Phản ánh phụ phí cao điểm và gián tiếp phản ánh tình trạng giao thông.
- Cuối tuần: Kiểm tra xem mô hình giao thông cuối tuần có ảnh hưởng đến giá cước không.

3.2 Mô tả biến số trong mô hình

3.2.1 Biến phụ thuộc

Biến `gia_cuoc_cb` được lấy từ cột `fare_amount` chính là số tiền cước phí của chuyến đi, được tính bằng đơn vị USD. Biến này được ghi nhận tự động từ đồng hồ tính tiền trên xe taxi, bao gồm giá mở cửa và phí theo quãng đường/thời gian, nhưng không bao gồm tiền tip, phí cầu đường, thuế và các khoản phụ thu khác.

3.2.2 Biến độc lập

Nghiên cứu sử dụng 4 biến độc lập, bao gồm 2 biến liên tục và 2 biến giả:

Bảng 3: Mô tả các biến trong mô hình hồi quy

Tên biến	Ý nghĩa	Loại biến	Mô tả chi tiết
gia_cuoc_cb	Giá cước	Phụ thuộc	Số tiền cước phí chuyển đi (USD)
do_dai_qd	Quãng đường	Liên tục	Khoảng cách di chuyển tính bằng dặm đo bằng GPS
thoi_gian_ht	Thời gian	Liên tục	Thời gian hành trình (phút), tính từ lúc đón đến lúc trả khách
gio_cao_diem	Giờ cao điểm	Giả (0/1)	= 1 nếu đón khách vào 7-9 giờ hoặc 16-19 giờ; = 0 nếu ngược lại
cuoi_tuan	Cuối tuần	Giả (0/1)	= 1 nếu đón khách vào Thứ 7 hoặc Chủ nhật; = 0 nếu ngược lại

3.3 Quy trình thu thập và xử lý dữ liệu

3.3.1 Thu thập dữ liệu

Dữ liệu được tải trực tiếp từ trang web của NYC TLC dưới định dạng Parquet – một định dạng lưu trữ dữ liệu hiệu quả, được tối ưu hóa cho việc xử lý dữ liệu lớn. File dữ liệu gốc chứa hàng triệu bản ghi về các chuyến đi taxi trong tháng 11/2025, nhưng sau đó tôi đã lấy ngẫu nhiên 5000 quan sát để nghiên cứu.

3.3.2 Làm sạch dữ liệu

Quá trình làm sạch dữ liệu được thực hiện theo các bước sau:

- Loại bỏ giá trị bất hợp lệ: Xóa các quan sát có giá cước âm hoặc bằng 0, quãng đường âm, thời gian hành trình âm.
- Lọc theo ngưỡng hợp lý: Giữ lại các chuyến đi có giá cước từ 2.5 USD đến 200 USD, quãng đường trên 0.1 dặm, thời gian từ 1 đến 180 phút.
- Xử lý ngoại lai: Sử dụng phương pháp IQR (Interquartile Range) để phát hiện và loại bỏ các giá trị ngoại lai của biến giá cước. Cụ thể, loại bỏ các quan sát có giá trị vượt quá $Q3 + 1.5 \times IQR$.

3.3.3 Tạo biến mới

Từ dữ liệu gốc, các biến mới được tạo ra như sau:

- thoi_gian_ht**: Tính từ hiệu số giữa thời điểm trả khách được lấy từ cột **dropoff_datetime** và thời điểm đón khách trong cột **pickup_datetime**, chuyển đổi sang đơn vị phút.
- gio_cao_diem**: Trích xuất giờ từ thời điểm đón khách, gán giá trị 1 nếu thuộc khung giờ cao điểm (7-9 giờ sáng hoặc 16-19 giờ chiều), ngược lại gán giá trị 0.
- cuoi_tuan**: Trích xuất ngày trong tuần từ thời điểm đón khách, gán giá trị 1 nếu là Thứ 7 hoặc Chủ nhật, ngược lại gán giá trị 0.

3.4 Kỹ thuật thống kê sử dụng

3.4.1 Thống kê mô tả

Thống kê mô tả được sử dụng để tóm tắt và trình bày đặc điểm của dữ liệu, bao gồm: giá trị trung bình, độ lệch chuẩn, giá trị nhỏ nhất, giá trị lớn nhất và giá trị trung vị. Để có thể nhìn thấy được tổng quát về bộ dữ liệu

3.4.2 Phân tích tương quan

Hệ số tương quan r được sử dụng để đo lường mức độ và chiều hướng của mối quan hệ tuyến tính giữa các biến. Ma trận tương quan được trình bày dưới dạng bản đồ nhiệt để dễ dàng nhận diện các cặp biến có tương quan cao, từ đó phát hiện nguy cơ đa cộng tuyến. Nếu có biến độc lập nào có tương quan xấp xỉ bằng 0 với biến phụ thuộc thì sẽ loại bỏ ra khỏi mô hình hồi quy.

3.4.3 Mô hình hồi quy tuyến tính bội

Mô hình hồi quy tuyến tính bội được sử dụng để ước lượng mối quan hệ giữa biến phụ thuộc và các biến độc lập. Dạng tổng quát của mô hình:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \varepsilon \quad (3.1)$$

Trong đó:

- Y : Giá cước (`gia_cuoc_cb`)
- X_1 : Quãng đường (`do_dai_qd`)
- X_2 : Thời gian (`thoi_gian_ht`)
- X_3 : Giờ cao điểm (`gio_cao_diem`)
- X_4 : Cuối tuần (`cuoi_tuan`)
- β_0 : Hệ số chặn
- $\beta_1, \beta_2, \beta_3, \beta_4$: Các hệ số hồi quy riêng phần
- ε : Sai số ngẫu nhiên

Phương pháp ước lượng được sử dụng là phương pháp BPNN, nhằm tối thiểu hóa tổng bình phương các phần dư.

3.4.4 Kiểm định giả thuyết thống kê

Các kiểm định thống kê được thực hiện bao gồm:

- **Kiểm định F**: Kiểm tra ý nghĩa thống kê của toàn bộ mô hình.
 - Giả thuyết $H_0 : \beta_1 = \beta_2 = \beta_3 = \beta_4 = 0$ (mô hình không có ý nghĩa).
 - Giả thuyết $H_1 : \exists j \in \{1, 2, 3, 4\} : \beta_j \neq 0$ (mô hình có ý nghĩa).
 - Tiêu chuẩn kiểm định: $f_0 = \frac{MS_R}{MS_E}$
 - Miền bác bỏ: $W_\alpha = \{f_0 \mid f_0 > f_\alpha(k, n - k - 1)\}$

- Nếu $f_0 > f_\alpha(k, n - k - 1)$, bác bỏ H_0 .
- **Kiểm định t:** Kiểm tra ý nghĩa thống kê của từng hệ số hồi quy riêng lẻ.
 - Giả thuyết $H_0 : \beta_j = 0$ (biến X_j không có ảnh hưởng đến Y).
 - Giả thuyết $H_1 : \beta_j \neq 0$ (biến X_j có ảnh hưởng đến Y).
 - Tiêu chuẩn kiểm định: $t_0 = \frac{\hat{\beta}_j}{se(\hat{\beta}_j)}$
 - Miền bác bỏ: $W_\alpha = \{t_0 \mid |t_0| > t_{\alpha/2}(n - k - 1)\}$
 - Nếu $|t_0| > t_{\alpha/2}(n - k - 1)$, bác bỏ H_0 .

3.4.5 Đánh giá mô hình

Chất lượng mô hình được đánh giá thông qua các chỉ số:

- Hệ số xác định R^2 : Đo lường tỷ lệ phương sai của biến phụ thuộc được giải thích bởi các biến độc lập. Giá trị từ 0 đến 1, càng cao càng tốt.
- Hệ số xác định R^2 hiệu chỉnh: Điều chỉnh R^2 theo số lượng biến độc lập, tránh việc R^2 tăng giả tạo khi thêm biến không có ý nghĩa.
- Phân tích phần dư: Kiểm tra các giả định của mô hình hồi quy tuyến tính bội thông qua biểu đồ phần dư và Q-Q plot để đánh giá tính chuẩn của phần dư.

3.4.6 Lựa chọn mô hình

Phương pháp loại bỏ ngược được sử dụng để lựa chọn mô hình tối ưu. Quy trình: bắt đầu với mô hình đầy đủ chứa tất cả các biến, sau đó lần lượt loại bỏ các biến không có ý nghĩa thống kê cho đến khi tất cả các biến còn lại đều có ý nghĩa.

3.5 Công cụ phân tích

Nghiên cứu sử dụng ngôn ngữ lập trình Python với các thư viện sau:

- pandas: Xử lý và thao tác dữ liệu
- numpy: Tính toán số học
- matplotlib, seaborn: Trực quan hóa dữ liệu
- scipy.stats: Kiểm định thống kê
- statsmodels: Xây dựng và ước lượng mô hình hồi quy tuyến tính bội

4 Kết quả và phân tích

Trong phần này, chúng tôi trình bày các kết quả phân tích dữ liệu từ mẫu nghiên cứu gồm 5000 chuyến đi của dịch vụ Yellow Taxi. Quy trình phân tích đi từ thống kê mô tả, kiểm tra tương quan, kiểm định đa cộng tuyến đến việc xây dựng và đánh giá mô hình hồi quy tuyến tính bội.

4.1 Thống kê mô tả mẫu nghiên cứu

4.1.1 Xử lý dữ liệu và làm sạch

Trước khi đi vào phân tích chi tiết, dữ liệu thô đã được qua các bước làm sạch để đảm bảo tính chính xác.

- Mẫu ban đầu: 5000 quan sát.
- Quy trình xử lý: Loại bỏ các giá trị thiếu, các chuyến đi có quãng đường bằng 0, cước phí âm và đặc biệt là xử lý các giá trị ngoại lai bằng phương pháp IQR đối với biến giá cước.
- Mẫu cuối cùng: Sau khi lọc bỏ các giá trị ngoại lai, kích thước mẫu còn lại là 4541 quan sát, đảm bảo tính đại diện và phân phối chuẩn hơn cho dữ liệu.

4.1.2 Thống kê mô tả các biến

Bảng dưới đây tóm tắt các đặc điểm thống kê cơ bản của các biến liên tục trong mô hình sau khi làm sạch:

Bảng 4: Thống kê mô tả các biến liên tục					
Biến	Trung bình	ĐLC	Nhỏ nhất	Trung vị	Lớn nhất
gia_cuoc_cb	12,50	9,20	2,50	9,50	52,00
do_dai_qd	2,90	3,40	0,10	1,80	25,00
thoi_gian_ht	13,50	10,10	1,00	10,00	60,00

Nguồn: Kết quả phân tích từ phần mềm

Nhận xét: Giá cước trung bình (gia_cuoc_cb) và quãng đường trung bình (do_dai_qd) phản ánh đặc điểm của các chuyến đi ngắn và trung bình trong nội đô New York. Độ lệch chuẩn (ĐLC) cho thấy mức độ biến động của dữ liệu quanh giá trị trung bình.

Đối với các biến định tính, tần suất xuất hiện như sau:

Bảng 5: Phân phối tần suất các biến định tính			
Biến	Phân loại	Số lượng	Tỷ lệ (%)
cuoi_tuan	Ngày thường (0)	3200	70,5
	Cuối tuần (1)	1341	29,5
gio_cao_diem	Ngoài cao điểm (0)	3400	74,9
	Giờ cao điểm (1)	1141	25,1

Nhận xét: Tỷ lệ các chuyến đi trong giờ cao điểm và cuối tuần phản ánh đúng nhu cầu đi lại thực tế, đảm bảo mẫu có đủ sự đa dạng để phân tích ảnh hưởng của các yếu tố này.


4.2 Phân tích tương quan

Để đánh giá sơ bộ mối quan hệ giữa các biến, ma trận tương quan đã được thiết lập.

Kết quả phân tích cho thấy:

- do_dai_qd với gia_cuoc_cb: Hệ số tương quan $r = 0.88$. Đây là mối tương quan dương rất mạnh, cho thấy quãng đường là yếu tố quyết định chính đến giá cước.

- `thoi_gian_ht` với `gia_cuoc_cb`: Hệ số tương quan $r = 0.91$. thời gian hành trình cũng có mối quan hệ rất chặt chẽ với giá cước.
- `cuoi_tuan` với `gia_cuoc_cb`: Hệ số tương quan $r = 0.00$. Cho thấy rằng ngày cuối tuần hay ngày thường không có sự tương quan tuyến tính với giá cước cơ bản. Nên ta sẽ loại biến `cuoi_tuan` ra khỏi mô hình.
- Mối quan hệ giữa các biến độc lập: Đáng chú ý nhất đó chính là hai biến `do_dai_qd` và `thoi_gian_ht` có tương quan cao khá cao với nhau. Điều này cảnh báo khả năng xảy ra hiện tượng đa cộng tuyến nhưng vì $r = 0.62$ nên khó có khả năng xảy ra hiện tượng đa cộng tuyến hoàn hảo mà ta lo ngại, nên ta có thể loại trừ khả năng này.



Hình 1: Ma trận tương quan giữa các biến

4.3 Kết quả mô hình hồi quy

4.3.1 Thiết lập mô hình và kết quả ước lượng ban đầu

Mô hình hồi quy tuyến tính bội tổng quát được thiết lập để nghiên cứu tác động của các yếu tố đến giá cước taxi như sau:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \varepsilon \quad (4.1)$$

Trong đó:

- Y : Giá cước (`gia_cuoc_cb`)
- X_1 : Quãng đường (`do_dai_qd`)
- X_2 : Thời gian hành trình (`thoi_gian_ht`)
- X_3 : Biến giả giờ cao điểm (`gio_cao_diem`)

- ε : Sai số ngẫu nhiên

Tiến hành ước lượng BPNN trên phần mềm Python, ta thu được kết quả như sau:

Bảng 6: Kết quả ước lượng mô hình hồi quy đầy đủ

Biến	Hệ số ($\hat{\beta}$)	Sai số chuẩn
Hệ số chặn	2,2063	0,029
do_dai_qd	2,3535	0,010
thoi_gian_ht	0,5575	0,002
gio_cao_diem	-0,0232	0,028

Bảng 7: Các chỉ số đánh giá mô hình đầy đủ

Chỉ số	Giá trị
R^2	0,986
R^2 hiệu chỉnh	0,986

Phương trình hồi quy ước lượng:

$$\hat{Y} = 2.2063 + 2.3535 \cdot X_1 + 0.5575 \cdot X_2 - 0.0232 \cdot X_3 \quad (4.2)$$

Hay viết dưới dạng tên biến:

$$\widehat{\text{gia_cuoc_cb}} = 2,2063 + 2,3535 \cdot \text{do_dai_qd} + 0,5575 \cdot \text{thoi_gian_ht} - 0,0232 \cdot \text{gio_cao_diem} \quad (4.3)$$

Nhận xét sơ bộ:

- Mô hình có $R^2 = 0,986$, cho thấy các biến độc lập giải thích được 98,6% sự biến thiên của giá cước.
- Hệ số của biến `gio_cao_diem` có giá trị rất nhỏ ($-0,0232$) ta khá nghi ngờ nên sẽ cần kiểm định thêm để xác định có nên giữ lại biến này hay không.

4.3.2 Kiểm định sự phù hợp của mô hình

Trước khi đi vào chi tiết từng biến, ta thực hiện kiểm định F để đánh giá xem mô hình tổng thể có ý nghĩa thống kê hay không.

Cặp giả thuyết:

- $H_0 : \beta_1 = \beta_2 = \beta_3 = \beta_4 = 0$ (Mô hình không phù hợp)
- $H_1 : \exists j \in \{1, 2, 3, 4\} : \beta_j \neq 0$ (Mô hình phù hợp)

Thông số kiểm định:

- Mức ý nghĩa $\alpha = 0,05$
- Bậc tự do tử số: $k = 4$
- Bậc tự do mẫu số: $n - k - 1 = 4536$

Tiêu chuẩn kiểm định:

- Giá trị tới hạn (tra bảng): $f_{\alpha}(k, n - k - 1) = f_{0,05}(4, 4536) = 2,3739$
- Giá trị quan sát (tính từ mẫu): $f_0 = \frac{MS_R}{MS_E} = 82396,0789$

Miền bác bỏ:

$$W_{\alpha} = \{f_0 \mid f_0 > f_{0,05}(4, 4536) = 2,3739\} \quad (4.4)$$

Kết luận: Vì $f_0 = 82396,0789 > f_{\alpha} = 2,3739$, giá trị quan sát rơi vào miền bác bỏ W_{α} . Do đó, ta bác bỏ giả thuyết H_0 ở mức ý nghĩa 5%. Mô hình hồi quy có ý nghĩa thống kê, các biến độc lập được đưa vào có khả năng giải thích sự biến thiên của giá cước.

4.3.3 Kiểm định hệ số hồi quy riêng

Tiếp theo, ta xét ý nghĩa thống kê của từng biến độc lập thông qua kiểm định t .

Cặp giả thuyết:

- $H_0 : \beta_j = 0$ (Biến X_j không ảnh hưởng đến Y)
- $H_1 : \beta_j \neq 0$ (Biến X_j có ảnh hưởng đến Y)

Thông số kiểm định:

- Mức ý nghĩa $\alpha = 0.05$
- Bậc tự do: $n - k - 1 = 4536$
- Giá trị tới hạn: $t_{\alpha/2}(4536) = t_{0,025}(4536) = 1.9605$
- Miền bác bỏ: $W_{\alpha} = \{t_0 \mid |t_0| > 1,9605\}$

Bảng dưới đây tổng hợp kết quả kiểm định t cho các hệ số:

Bảng 8: Kết quả kiểm định t của các hệ số hồi quy (Mô hình đầy đủ)

Biến	Hệ số (β)	t_0	$ t_0 $	Kết luận
Hệ số chặn(β_0)	2,2063	76,4789	76,4789	Bác bỏ H_0
do_dai_qd	2,3535	228,2267	228,2267	Bác bỏ H_0
thoi_gian_ht	0,5575	267,5787	267,5787	Bác bỏ H_0
gio_cao_diem	-0,0232	-0,8258	0,8258	Chưa đủ cơ sở bác bỏ H_0

Phân tích kết quả:


- Các biến β_0 , do_dai_qd và $thoi_gian_ht$ đều có $|t_0| > t_{0,025}(4536) = 1.9605$, rơi vào miền bác bỏ W_{α} . Do đó, ta bác bỏ H_0 và kết luận các biến này có ý nghĩa thống kê ở mức 5%.
- Biến gio_cao_diem : Có $|t_0| = 0,8258 < 1,9605$, không rơi vào miền bác bỏ. Do đó, ta chưa có cơ sở để bác bỏ H_0 , tức là tác động của giờ cao điểm lên giá cước không có ý nghĩa thống kê.

Quyết định: Loại bỏ hai biến gio_cao_diem khỏi mô hình, sau đó tiến hành kiểm tra các giả định của mô hình hồi quy trước khi đưa ra kết quả cuối cùng.

4.4 Kiểm định các giả thiết của mô hình hồi quy

Trước khi công bố mô hình cuối cùng, ta cần kiểm tra tính đúng đắn của các giả thiết trong mô hình hồi quy tuyến tính bội. Việc kiểm tra này đảm bảo các ước lượng BPNN là đáng tin cậy và có thể sử dụng để suy diễn thống kê.

Sau khi loại bỏ hai biến không có ý nghĩa thống kê, ta tiến hành ước lượng lại mô hình với hai biến `do_dai_qd` và `thoi_gian_ht`, sau đó phân tích phần dư để kiểm tra các giả thiết.



Hình 2: Chẩn đoán phần dư của mô hình hồi quy

4.4.1 Kiểm tra phân phối chuẩn của phần dư

Phương pháp 1: Biểu đồ Histogram

Biểu đồ histogram của phần dư cho thấy:

- Phần dư tập trung quanh giá trị 0, đây là dấu hiệu tốt cho thấy mô hình không có sai lệch hệ thống.
- Phân phối có dạng đỉnh nhọn, độ nhọn cao hơn phân phối chuẩn.
- Đuôi phải của phân phối khá dài cho thấy có nhiều ngoại lai dương.

Phương pháp 2: Biểu đồ Q-Q Plot

Biểu đồ Q-Q Plot so sánh phân vị của phần dư với phân vị lý thuyết của phân phối chuẩn:

- Phần lớn các điểm ở vùng trung tâm nằm sát đường thẳng lý thuyết, cho thấy phần dư tuân theo phân phối chuẩn ở vùng giữa.
- Ở hai đuôi đặc biệt là đuôi phải, các điểm lệch khỏi đường thẳng đáng kể, xác nhận phần dư có đuôi nặng hơn phân phối chuẩn.

Nhận xét: Giả thiết phần dư có phân phối chuẩn bị vi phạm nhẹ. Tuy nhiên ta có thể chấp nhận với cỡ mẫu lớn.

4.4.2 Kiểm tra tính đồng nhất phương sai của sai số

Biểu đồ Giá trị dự báo với phần dư được sử dụng để kiểm tra giả thiết phương sai sai số đồng nhất:

- Các điểm phần dư phân tán khá đều quanh đường $y = 0$, không xuất hiện xu hướng tăng hoặc giảm rõ ràng.

- Không có hình dạng phổ biến điển hình của hiện tượng phương sai thay đổi.
- Tuy nhiên, có một số điểm ngoại lai dương ở vùng giá trị dự báo trong khoảng 10-20 USD.

Nhận xét: Giả thiết phương sai sai số đồng nhất được thỏa mãn ở mức chấp nhận được. Các điểm ngoại lai không tạo thành quy luật hệ thống.

4.4.3 Tổng hợp kết quả kiểm định giả thiết

Bảng 9: Tổng hợp kết quả kiểm tra các giả thiết của mô hình		
Giả thiết	Phương pháp kiểm tra	Kết luận
Phần dư phân phối chuẩn	Histogram, Q-Q Plot	Chấp nhận được
Phương sai đồng nhất	Biểu đồ Giá trị dự báo	Thỏa mãn

Kết luận: Mặc dù giả thiết phân phối chuẩn của phần dư bị vi phạm nhẹ, mô hình vẫn đáng tin cậy vì:

1. Cỡ mẫu đủ lớn ($n = 4541$) để đảm bảo tính vững của ước lượng BPNN .
2. Không có vi phạm nghiêm trọng về phương sai đồng nhất.
3. Các vi phạm chủ yếu do một số điểm ngoại lai, không phải do sai lệch hệ thống của mô hình.

Do đó, ta có thể tin tưởng sử dụng kết quả ước lượng để xây dựng mô hình cuối cùng.

4.5 Kết quả mô hình cuối cùng

Sau khi kiểm tra các giả thiết và xác nhận mô hình đáng tin cậy, ta công bố kết quả ước lượng của mô hình cuối cùng:

Bảng 10: Kết quả ước lượng Mô hình cuối cùng

Biến	Hệ số (β)	Sai số chuẩn
Hệ số chặn	2,2384	0,027
do_dai_qd	2,3588	0,010
thoi_gian_ht	0,5566	0,002

Các chỉ số đánh giá mô hình:

- $R^2 = 0,986$: Mô hình giải thích được 98,6% sự biến thiên của giá cước taxi.
- R^2 hiệu chỉnh = 0,986: Giá trị bằng R^2 , khẳng định không có hiện tượng overfitting.

Phương trình hồi quy tuyến tính thực nghiệm:

$$\widehat{\text{gia_cuoc_cb}} = 2,2384 + 2,3588 \times \text{do_dai_qd} + 0,5566 \times \text{thoi_gian_ht} \quad (4.5)$$

Diễn giải ý nghĩa các hệ số:

1. Hệ số chặn $\hat{\beta}_0 = 2,24$ USD: Đây là mức giá cước khởi điểm khi lên xe, tương ứng với giá mở cửa của taxi NYC. Giá trị này khá sát với thực tế là khoảng 2,50 đến 3,00 USD.
2. Hệ số quãng đường $\hat{\beta}_1 = 2,36$ USD/dặm: Với mỗi dặm di chuyển tăng thêm, giá cước dự kiến tăng trung bình 2,36 USD với điều kiện thời gian không đổi. Hệ số này phản ánh cơ chế tính phí theo quãng đường của NYC TLC.
3. Hệ số thời gian $\hat{\beta}_2 = 0,56$ USD/phút: Với mỗi phút thời gian hành trình tăng thêm (do di chuyển chậm, tắc đường, hoặc chờ đợi), giá cước dự kiến tăng trung bình 0,56 USD. Hệ số này phản ánh cơ chế tính phí theo thời gian khi xe di chuyển dưới 12 mph hoặc dừng đỗ.

Lý do loại bỏ các biến:

- **Biến cuoi_tuan:** Hệ số tương quan với giá cước gần bằng 0 ($r \approx 0$), cho thấy không có mối liên hệ tuyến tính giữa ngày cuối tuần và giá cước.
- **Biến gio_cao_diem:** Mặc dù về tính thực tế giờ cao điểm có thể ảnh hưởng đến giá cước, kiểm định t cho thấy tác động này không có ý nghĩa thống kê trong mẫu dữ liệu ($|t_0| = 0,8258 < 1,9605$). Điều này có thể giải thích bởi:
 - (1) NYC TLC tách riêng phụ phí giờ cao điểm khỏi `gia_cuoc_cb` cơ bản.
 - (2) Tác động của giờ cao điểm đã được phản ánh gián tiếp qua biến `thoi_gian_ht`.

4.5.1 Ứng dụng mô hình: Dự đoán giá cước cho quan sát mới

Sau khi xây dựng được mô hình hồi quy, ta có thể sử dụng mô hình để dự đoán giá cước cho các chuyến đi mới. Áp dụng công thức khoảng dự đoán (2.17), ta tính toán giá trị dự đoán điểm và khoảng dự đoán 95% cho một số kịch bản chuyến đi.

Ví dụ minh họa:

Giả sử một hành khách muốn ước tính giá cước cho chuyến đi với quãng đường 5 dặm và thời gian hành trình là 20 phút.

Giá trị dự đoán điểm:

$$\hat{y}_0 = 2,2384 + 2,3588 \times 5 + 0,5566 \times 20 = 25,16 \text{ USD} \quad (4.6)$$

Khoảng dự đoán 95%: Áp dụng công thức (2.17) với $\alpha = 0,05$, $n - p = 4538$, ta thu được:

Chuyến đi	Dự đoán điểm	Cận dưới	Cận trên
5 dặm, 20 phút	25,16 USD	22,89 USD	27,43 USD

Diễn giải: Với độ tin cậy 95%, giá cước cho chuyến đi 5 dặm trong 20 phút được dự đoán nằm trong khoảng từ 22,89 USD đến 27,43 USD.

Dự đoán cho các kịch bản khác:

Bảng 12: Dự đoán giá cước cho các kịch bản chuyến đi khác nhau

Kịch bản	Quãng đường	Thời gian	Ước lượng	KĐĐ
Chuyến ngắn	1 dặm	5 phút	7,38 USD	[5,11, 9,65]
Chuyến trung bình	3 dặm	15 phút	17,70 USD	[15,43, 19,97]
Chuyến dài	10 dặm	40 phút	48,16 USD	[45,89, 50,43]
Tắc đường	2 dặm	30 phút	23,62 USD	[21,35, 25,89]

Nhận xét:

- Khoảng dự đoán (KDD) có độ rộng khoảng 4-5 USD, phản ánh sự biến động tự nhiên của giá cước.
- Chuyến đi tắc đường (2 dặm, 30 phút) có giá cao hơn chuyến trung bình (3 dặm, 15 phút) do thời gian hành trình dài hơn.
- Mô hình cho phép hành khách ước tính trước chi phí với độ tin cậy lên đến 95%.

5 Nhận xét và kết luận

5.1 Ý nghĩa thống kê của kết quả

Mô hình hồi quy tuyến tính bội được xây dựng đã cho thấy kết quả có ý nghĩa thống kê cao:

- Mô hình tổng thể có ý nghĩa: Sau khi kiểm định F ta đã bác bỏ giả thuyết cho rằng mô hình không có ý nghĩa sau đó khẳng định các biến độc lập có khả năng giải thích sự biến thiên của giá cước.
- Khả năng giải thích cao: Hệ số $R^2 = 0,986$ cho thấy mô hình giải thích được 98,6% sự biến thiên của giá cước taxi, đây là mức độ phù hợp rất cao hoàn toàn có thể áp dụng vào thực tế.
- Hai biến có ý nghĩa thống kê: Quãng đường (do_dai_qd), thời gian hành trình ($thoi_gian_ht$) đều đã được chứng minh rằng tác động của chúng lên giá cước là có thật và không phải do ngẫu nhiên.
- Biến giờ cao điểm không có ý nghĩa: Ta đã chứng minh được rằng biến gio_cao_diem không có ý nghĩa thống kê trong bộ dữ liệu này nói cách khác với bộ dữ liệu này thì giờ cao điểm không tạo ra sự khác biệt có ý nghĩa thống kê đối với giá cước cơ bản.

5.2 Ý nghĩa thực tiễn của kết quả

Kết quả nghiên cứu phản ánh khá sát thực tế vận hành của hệ thống taxi tại New York:

- Cấu trúc giá cước hợp lý: Phương trình hồi quy (4.3) phù hợp với cơ chế tính giá của NYC TLC, bao gồm giá mở cửa cố định, phí theo dặm, và phí theo thời gian chờ/di chuyển chậm.
- Hệ số chặn ($\hat{\beta}_0 = 2,24$ USD): Tương ứng với mức giá khởi điểm khi lên xe, gần với giá mở cửa thực tế của taxi NYC (khoảng 2,50-3,00 USD).
- Hệ số của độ dài quãng đường ($\hat{\beta}_1 = 2,36$ USD/dặm): Mỗi dặm di chuyển làm tăng giá cước khoảng 2,36 USD, khá sát với biểu giá chính thức của NYC (khoảng 2,50 USD/dặm).
- Hệ số của độ dài thời gian đi ($\hat{\beta}_2 = 0,56$ USD/phút): Chi phí cho mỗi phút di chuyển hoặc chờ đợi, phản ánh cơ chế tính phí theo thời gian khi xe di chuyển chậm hoặc dừng đỗ.
- Giúp ích được cho khách hàng biết trước khoảng giá cước phải trả với độ tin cậy cao.
- Giúp cho các quản lý công ty xác thực được độ tin cậy của đồng hồ tính tiền.

5.3 Phản biện kết quả và hạn chế của nghiên cứu

Mặc dù mô hình đạt kết quả tốt, nghiên cứu vẫn tồn tại một số hạn chế cần được nhìn nhận:

- Vi phạm nhẹ giả định phân phối chuẩn: Phần dư có độ nhọn cao và đuôi nặng, cho thấy phân phối không hoàn toàn chuẩn.
- Biến `gio_cao_diem` không có ý nghĩa. Kết quả này có thể do:
 - (1) NYC TLC đã tách riêng phụ phí giờ cao điểm khỏi `gia_cuoc_cb` cơ bản
 - (2) Định nghĩa giờ cao điểm (7-9 giờ và 16-19 giờ) chưa phù hợp với thực tế NYC
 - (3) Tác động của giờ cao điểm đã được phản ánh gián tiếp qua biến `thoi_gian_ht`.
- Hệ số R^2 khá cao: Giá trị $R^2 = 0,986$ có thể gây nghi ngờ về tính độc lập giữa các biến. Thực tế, `do_dai_qd` và `thoi_gian_ht` có tương quan khá cao ($r \approx 0,62$) ta có thể kiểm tra đa cộng tuyến để xem xét xem có hiện tượng đa cộng tuyến hoàn hảo hay không.
- Giới hạn về phạm vi dữ liệu: Nghiên cứu chỉ sử dụng 5000 quan sát ngẫu nhiên được lấy tại dữ liệu Yellow Taxi tháng 11/2025, có thể không đại diện cho các thời gian khác trong năm hay các dịp lễ đặc biệt.
- Biến phụ thuộc chưa đầy đủ: Biến `gia_cuoc_cb` chỉ bao gồm giá cước cơ bản, chưa tính đến tổng chi phí thực tế mà hành khách phải trả.
- Thiếu các yếu tố không gian: Mô hình chưa xem xét ảnh hưởng của vị trí đón hoặc trả khách, vốn là yếu tố quan trọng trong định giá cước taxi.

5.4 Đề xuất mở rộng nghiên cứu

Để khắc phục các hạn chế và nâng cao chất lượng nghiên cứu, một số hướng mở rộng được đề xuất:

- Mở rộng biến phụ thuộc: Sử dụng tổng chi phí thay vì giá cước cơ bản để phản ánh đầy đủ hơn chi phí thực tế của hành khách, bao gồm cả các khoản phụ phí và thuế.
- Bổ sung biến không gian: Thêm các biến về khu vực đón hoặc trả khách, phân loại theo quận (Manhattan, Brooklyn, Queens...) hoặc theo loại điểm đến (sân bay, trung tâm thương mại, khu dân cư).
- Xem xét yếu tố thời tiết: Kết hợp dữ liệu thời tiết để đánh giá tác động của điều kiện thời tiết lên giá cước và nhu cầu di chuyển.
- Mở rộng thời gian nghiên cứu: Thu thập dữ liệu nhiều tháng hoặc cả năm để phân tích xu hướng theo mùa và kiểm tra tính ổn định của mô hình.
- So sánh với các dịch vụ khác: Mở rộng nghiên cứu sang dữ liệu của Green taxi hoặc For-hive taxi để so sánh cấu trúc giá cước giữa các loại taxi với đặc trưng hoạt động khác nhau.
- Áp dụng mô hình khác để kiểm tra: Thử nghiệm các mô hình hồi quy phi tuyến hoặc biến đổi logarit để xử lý tốt hơn các giá trị ngoại lai và cải thiện phân phối phần dư.
- Định nghĩa lại giờ cao điểm: Nghiên cứu kỹ hơn về khung giờ cao điểm thực tế của thành phố New York và điều chỉnh biến `gio_cao_diem` cho phù hợp, hoặc sử dụng biến liên tục thay vì biến nhị phân.

5.5 Kết luận

Nghiên cứu đã xây dựng thành công mô hình hồi quy tuyến tính bội để phân tích các yếu tố ảnh hưởng đến giá cước cơ bản của Yellow Taxi tại New York vào tháng 11/2025. Kết quả cho thấy:

1. Mô hình với hai biến giải thích (`do_dai_qd`, `thoi_gian_ht`) giải thích được 98.6% sự biến thiên của giá cước, đạt mức độ phù hợp rất cao.
2. Quãng đường và thời gian hành trình là hai yếu tố quyết định chính đến giá cước, phù hợp với cơ chế tính giá của NYC TLC.
3. Ngày cuối tuần hay ngày thường không có sự tương quan tuyến tính với giá cước cơ bản.
4. Giờ cao điểm không có ý nghĩa thống kê trong mô hình, có thể do phụ phí giờ cao điểm được tách riêng khỏi giá cước cơ bản.
5. Mô hình đáp ứng các giả định cơ bản của hồi quy tuyến tính bội ở mức chấp nhận được, mặc dù có một số vi phạm nhẹ về phân phối chuẩn của phần dư.

Kết quả nghiên cứu cung cấp cái nhìn định lượng về cấu trúc giá cước taxi tại thành phố New York, có thể làm cơ sở cho các nghiên cứu sâu hơn về thị trường vận tải đô thị hoặc hỗ trợ hành khách ước tính chi phí di chuyển.

Tài liệu tham khảo

1. Nguyễn Thị Thu Thủy, *Bài giảng Suy luận Thống kê*, Khoa Toán - Tin, Đại học Bách Khoa Hà Nội, 2025.
2. New York City Taxi and Limousine Commission, *TLC Trip Record Data*, 2025. Truy cập tại: <https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page>.

A Phụ lục: Các chứng minh

A.1 Chứng minh công thức ước lượng BPNN

Định lý A.1 (Công thức ước lượng BPNN). Nếu ma trận $\mathbf{X}^T \mathbf{X}$ khả nghịch, ước lượng bình phương nhỏ nhất của β là:

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} \quad (\text{A.1})$$

Chứng minh. Bước 1: Khai triển hàm mục tiêu

Hàm mục tiêu của phương pháp BPNN:

$$L(\beta) = (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta)$$

Khai triển:

$$L(\beta) = \mathbf{y}^T \mathbf{y} - \mathbf{y}^T \mathbf{X}\beta - \beta^T \mathbf{X}^T \mathbf{y} + \beta^T \mathbf{X}^T \mathbf{X}\beta$$

Vì $\mathbf{y}^T \mathbf{X}\beta$ là vô hướng, ta có $\mathbf{y}^T \mathbf{X}\beta = \beta^T \mathbf{X}^T \mathbf{y}$, do đó:

$$L(\beta) = \mathbf{y}^T \mathbf{y} - 2\beta^T \mathbf{X}^T \mathbf{y} + \beta^T \mathbf{X}^T \mathbf{X}\beta$$

Bước 2: Tính đạo hàm và tìm điều kiện cực trị

Sử dụng các công thức đạo hàm ma trận:

- $\frac{\partial}{\partial \beta}(\beta^T \mathbf{a}) = \mathbf{a}$ với $\mathbf{a}$ là vector hằng
- $\frac{\partial}{\partial \beta}(\beta^T \mathbf{A}\beta) = 2\mathbf{A}\beta$ với $\mathbf{A}$ là ma trận đối xứng

Lấy đạo hàm theo β :

$$\frac{\partial L}{\partial \beta} = -2\mathbf{X}^T \mathbf{y} + 2\mathbf{X}^T \mathbf{X}\beta$$

Cho đạo hàm bằng 0:

$$-2\mathbf{X}^T \mathbf{y} + 2\mathbf{X}^T \mathbf{X}\beta = \mathbf{0}$$

Bước 3: Giải phương trình chuẩn

Sắp xếp lại ta được phương trình chuẩn:

$$\mathbf{X}^T \mathbf{X}\beta = \mathbf{X}^T \mathbf{y} \quad (\text{A.2})$$

Nếu $\mathbf{X}^T \mathbf{X}$ khả nghịch, nhân hai vế với $(\mathbf{X}^T \mathbf{X})^{-1}$:

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

Bước 4: Kiểm tra điều kiện đủ

Ma trận Hessian:

$$\mathbf{H} = \frac{\partial^2 L}{\partial \beta \partial \beta^T} = 2\mathbf{X}^T \mathbf{X}$$

Ta chứng minh $\mathbf{X}^T \mathbf{X}$ là ma trận xác định dương. Với mọi vector $\mathbf{v} \neq \mathbf{0}$:

$$\mathbf{v}^T (\mathbf{X}^T \mathbf{X}) \mathbf{v} = (\mathbf{X}\mathbf{v})^T (\mathbf{X}\mathbf{v}) = \|\mathbf{X}\mathbf{v}\|^2 \geq 0$$

Dấu "=" xảy ra khi và chỉ khi $\mathbf{X}\mathbf{v} = \mathbf{0}$. Do $\text{rank}(\mathbf{X}) = p$ (giả thiết không đa cộng tuyến hoàn hảo), nên $\mathbf{X}\mathbf{v} = \mathbf{0}$ chỉ khi $\mathbf{v} = \mathbf{0}$.

Vậy $\mathbf{X}^T \mathbf{X}$ xác định dương, suy ra $\hat{\beta}$ là điểm cực tiểu toàn cục. $\square$

A.2 Chứng minh tính không chệch của ước lượng BPNN

Định lý A.2 (Tính không chệch). Nếu $E(\boldsymbol{\varepsilon}|\mathbf{X}) = \mathbf{0}$, thì $E(\hat{\boldsymbol{\beta}}|\mathbf{X}) = \boldsymbol{\beta}$.

Chứng minh. Từ công thức ước lượng BPNN:

$$\begin{aligned}\hat{\boldsymbol{\beta}} &= (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} \\ &= (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T (\mathbf{X} \boldsymbol{\beta} + \boldsymbol{\varepsilon}) \quad (\text{thay } \mathbf{y} = \mathbf{X} \boldsymbol{\beta} + \boldsymbol{\varepsilon}) \\ &= (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{X} \boldsymbol{\beta} + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \boldsymbol{\varepsilon} \\ &= \mathbf{I}_p \boldsymbol{\beta} + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \boldsymbol{\varepsilon} \\ &= \boldsymbol{\beta} + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \boldsymbol{\varepsilon}\end{aligned}$$

Lấy kỳ vọng có điều kiện theo $\mathbf{X}$:

$$\begin{aligned}E(\hat{\boldsymbol{\beta}}|\mathbf{X}) &= \boldsymbol{\beta} + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T E(\boldsymbol{\varepsilon}|\mathbf{X}) \\ &= \boldsymbol{\beta} + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \cdot \mathbf{0} \\ &= \boldsymbol{\beta}\end{aligned}$$

□

A.3 Chứng minh ma trận hiệp phương sai của $\hat{\boldsymbol{\beta}}$

Định lý A.3 (Ma trận hiệp phương sai). Nếu $\text{Var}(\boldsymbol{\varepsilon}|\mathbf{X}) = \sigma^2 \mathbf{I}_n$, thì:

$$\text{Var}(\hat{\boldsymbol{\beta}}|\mathbf{X}) = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1} \quad (\text{A.3})$$

Chứng minh. Đặt $\mathbf{C} = (\mathbf{X}^T \mathbf{X})^{-1}$. Từ chứng minh tính không chệch:

$$\hat{\boldsymbol{\beta}} - \boldsymbol{\beta} = \mathbf{C} \mathbf{X}^T \boldsymbol{\varepsilon}$$

Ma trận hiệp phương sai:

$$\begin{aligned}\text{Var}(\hat{\boldsymbol{\beta}}|\mathbf{X}) &= E \left[(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})^T | \mathbf{X} \right] \\ &= E \left[(\mathbf{C} \mathbf{X}^T \boldsymbol{\varepsilon})(\mathbf{C} \mathbf{X}^T \boldsymbol{\varepsilon})^T | \mathbf{X} \right] \\ &= E \left[\mathbf{C} \mathbf{X}^T \boldsymbol{\varepsilon} \boldsymbol{\varepsilon}^T \mathbf{X} \mathbf{C}^T | \mathbf{X} \right] \\ &= \mathbf{C} \mathbf{X}^T E(\boldsymbol{\varepsilon} \boldsymbol{\varepsilon}^T | \mathbf{X}) \mathbf{X} \mathbf{C}^T\end{aligned}$$

Vì $E(\boldsymbol{\varepsilon} \boldsymbol{\varepsilon}^T | \mathbf{X}) = \text{Var}(\boldsymbol{\varepsilon}|\mathbf{X}) = \sigma^2 \mathbf{I}_n$:

$$\begin{aligned}\text{Var}(\hat{\boldsymbol{\beta}}|\mathbf{X}) &= \mathbf{C} \mathbf{X}^T (\sigma^2 \mathbf{I}_n) \mathbf{X} \mathbf{C}^T \\ &= \sigma^2 \mathbf{C} \mathbf{X}^T \mathbf{X} \mathbf{C}^T \\ &= \sigma^2 \mathbf{C} \cdot \mathbf{I}_p \cdot \mathbf{C}^T \quad (\text{vì } \mathbf{C} \mathbf{X}^T \mathbf{X} = \mathbf{I}_p) \\ &= \sigma^2 \mathbf{C} \mathbf{C}^T\end{aligned}$$

Vì $\mathbf{X}^T \mathbf{X}$ là ma trận đối xứng, nên $(\mathbf{X}^T \mathbf{X})^{-1}$ cũng đối xứng, tức $\mathbf{C}^T = \mathbf{C}$:

$$\text{Var}(\hat{\boldsymbol{\beta}}|\mathbf{X}) = \sigma^2 \mathbf{C}^2 = \sigma^2 \mathbf{C} = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}$$

□

A.4 Chứng minh tính không chệch của s^2

Định lý A.4. $E(s^2) = \sigma^2$, tức s^2 là ước lượng không chệch của σ^2 .

Chứng minh. Đặt $\mathbf{H} = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$ ta có:

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} = \mathbf{H}\mathbf{y}$$

Vector phần dư:

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = \mathbf{y} - \mathbf{H}\mathbf{y} = (\mathbf{I}_n - \mathbf{H})\mathbf{y} = \mathbf{M}\mathbf{y}$$

với $\mathbf{M} = \mathbf{I}_n - \mathbf{H}$.

Tính chất của $\mathbf{M}$:

- $\mathbf{M}$ đối xứng: $\mathbf{M}^T = \mathbf{M}$
- $\mathbf{M}$ lũy đẳng: $\mathbf{M}^2 = \mathbf{M}$
- $\text{trace}(\mathbf{M}) = n - p$

Ta có:

$$SSE = \mathbf{e}^T \mathbf{e} = (\mathbf{M}\mathbf{y})^T (\mathbf{M}\mathbf{y}) = \mathbf{y}^T \mathbf{M}^T \mathbf{M} \mathbf{y} = \mathbf{y}^T \mathbf{M} \mathbf{y}$$

Thay $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ và sử dụng $\mathbf{M}\mathbf{X} = \mathbf{0}$:

$$SSE = (\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon})^T \mathbf{M} (\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}) = \boldsymbol{\varepsilon}^T \mathbf{M} \boldsymbol{\varepsilon}$$

Lấy kỳ vọng, sử dụng công thức $E(\boldsymbol{\varepsilon}^T \mathbf{A} \boldsymbol{\varepsilon}) = \text{trace}(\mathbf{A})\sigma^2$ khi $E(\boldsymbol{\varepsilon}) = \mathbf{0}$ và $\text{Var}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}$:

$$E(SSE) = E(\boldsymbol{\varepsilon}^T \mathbf{M} \boldsymbol{\varepsilon}) = \text{trace}(\mathbf{M})\sigma^2 = (n - p)\sigma^2 \quad (\text{A.4})$$

Do đó:

$$E(s^2) = E\left(\frac{SSE}{n - p}\right) = \frac{(n - p)\sigma^2}{n - p} = \sigma^2$$

□

A.5 Chứng minh khoảng dự đoán cho quan sát mới

Định lý A.5. Khoảng dự đoán $(1 - \alpha)100\%$ cho quan sát mới Y_0 tại $\mathbf{x}_0$ là:

$$\hat{y}_0 - t_{\alpha/2, n-p} \cdot s \sqrt{1 + \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0} < Y_0 < \hat{y}_0 + t_{\alpha/2, n-p} \cdot s \sqrt{1 + \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0} \quad (\text{A.5})$$

Chứng minh. Quan sát mới Y_0 thỏa mãn: $Y_0 = \mathbf{x}_0^T \boldsymbol{\beta} + \varepsilon_0$ với $\varepsilon_0 \sim N(0, \sigma^2)$.

Sai số dự đoán:

$$Y_0 - \hat{y}_0 = (\mathbf{x}_0^T \boldsymbol{\beta} + \varepsilon_0) - \mathbf{x}_0^T \hat{\boldsymbol{\beta}} = \mathbf{x}_0^T (\boldsymbol{\beta} - \hat{\boldsymbol{\beta}}) + \varepsilon_0$$

Tính kỳ vọng:

$$E(Y_0 - \hat{y}_0) = \mathbf{x}_0^T E(\boldsymbol{\beta} - \hat{\boldsymbol{\beta}}) + E(\varepsilon_0) = \mathbf{0} + 0 = 0$$

Tính phương sai:

Vì ε_0 độc lập với $\hat{\boldsymbol{\beta}}$ (sai số của quan sát mới độc lập với dữ liệu dùng để ước lượng):

$$\begin{aligned}\text{Var}(Y_0 - \hat{y}_0) &= \text{Var}(\mathbf{x}_0^T(\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})) + \text{Var}(\varepsilon_0) \\ &= \text{Var}(\mathbf{x}_0^T\hat{\boldsymbol{\beta}}) + \sigma^2 \\ &= \sigma^2 \mathbf{x}_0^T(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{x}_0 + \sigma^2 \\ &= \sigma^2 (1 + \mathbf{x}_0^T(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{x}_0)\end{aligned}$$

Phân phối:

$$Y_0 - \hat{y}_0 \sim N(0, \sigma^2 (1 + \mathbf{x}_0^T(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{x}_0))$$

Thống kê pivot:

$$T = \frac{Y_0 - \hat{y}_0}{s\sqrt{1 + \mathbf{x}_0^T(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{x}_0}} \sim t(n - p)$$

Khoảng dự đoán: Từ $P(-t_{\alpha/2, n-p} \leq T \leq t_{\alpha/2, n-p}) = 1 - \alpha$, giải cho Y_0 ta được kết quả. $\square$